



PONTIFICIA
UNIVERSIDAD
CATÓLICA DE
VALPARAÍSO

Robótica e inteligencia artificial

pucv.cl

Módulo 4
Inteligencia artificial S25

INTELIGENCIA ARTIFICIAL

SESIÓN 25

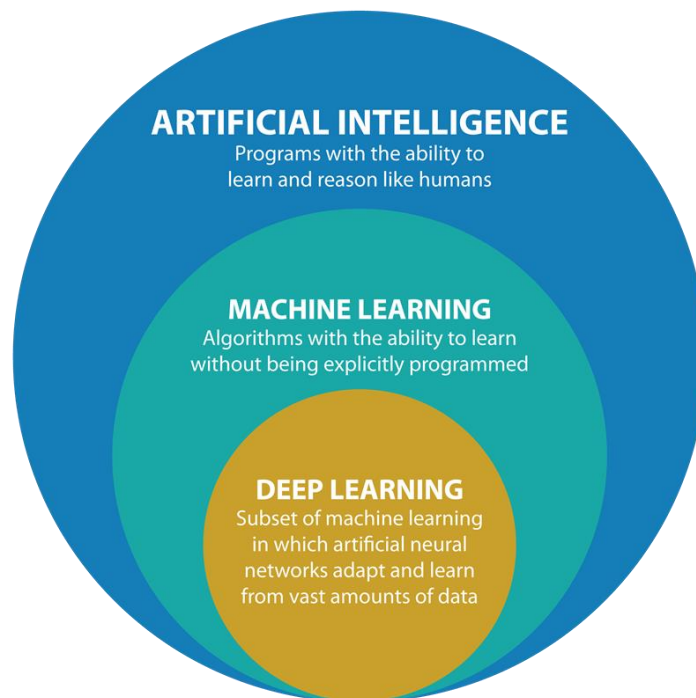
Subdivisiones de la IA

La inteligencia artificial posee subcampos denominados, Aprendizaje automático (Machine Learning) y aprendizaje profundo (Deep Learning).

Inteligencia artificial: Programas con la capacidad de aprender y razonar como los humanos

Aprendizaje automático: Algoritmos con la capacidad de aprender sin ser explícitamente programados


Aprendizaje profundo: Conjunto de aprendizajes automáticos en el que la red neuronal artificial se adapta y aprende de grandes cantidades de datos.



Machine Learning

Debido al aumento de la capacidad y el abaratamiento de las tecnologías de la información, es posible producir y almacenar gran cantidad de datos como nunca antes en la historia. en efecto, se calcula que el 90% de los datos disponibles actualmente en el planeta se han creado en los últimos dos años, produciéndose actualmente en torno a 2.5 quintillones de bytes por día y siguiendo una tendencia fuertemente creciente.

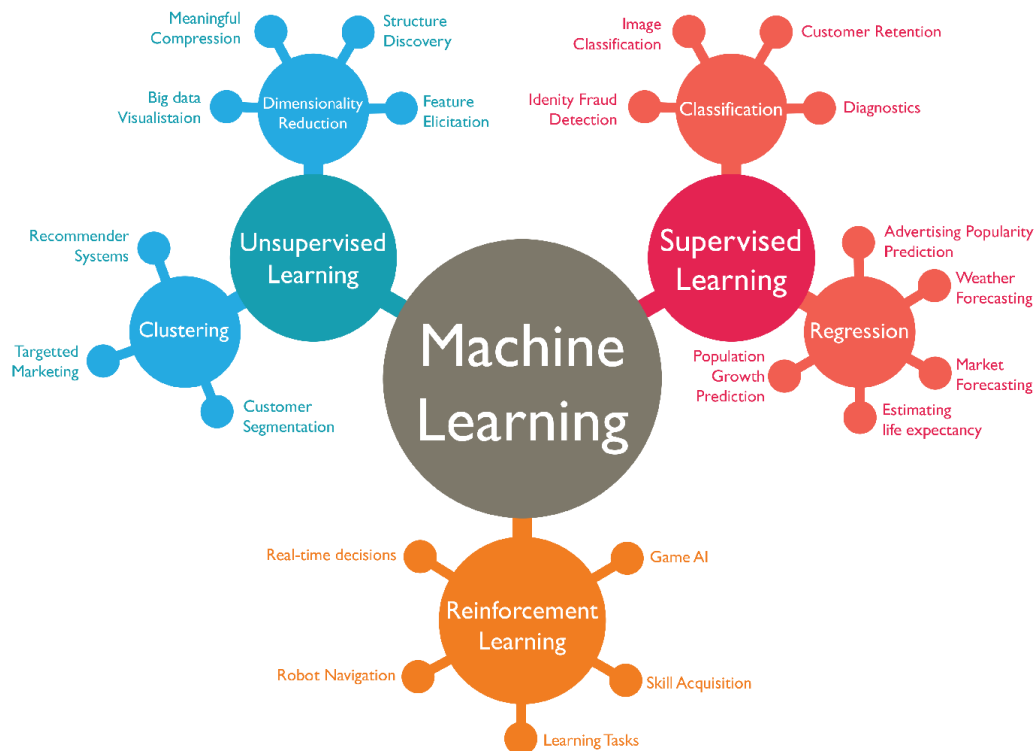
Estos datos alimentan los modelos de Machine Learning y son el impulso principal del auge que la ciencia ha experimentado en estos últimos años.



Machine Learning

El aprendizaje automático ofrece una manera eficiente de capturar el conocimiento mediante información contenida en los datos, para mejorar de forma gradual el rendimiento de modelos predictivos y tomar decisiones basadas en dichos datos.

Se ha convertido en una tecnología con una amplia presencia, y actualmente está presente en: filtros anti-spam para correo electrónico, conducción automática de vehículos o reconocimiento de voz e imágenes, entre muchas otras áreas.



Machine Learning

Las siguientes imágenes muestran una detección de eventos en tiempo real por una aplicación de video vigilancia basada en Machine Learning.



Terminología básica y notaciones

En Machine Learning generalmente se utilizan matrices y notaciones vectoriales para referirnos a los datos, de la siguiente forma:

- Cada fila de la matriz es una muestra, observación o dato puntual.
- Cada columna es una característica (o atributo), de la observación mencionada en el punto anterior (“feature” en la imagen inferior).
- En el caso más general habrá una columna, que llamaremos objetivo, etiqueta o respuesta, y que será el valor que se pretende predecir. (“label” en la imagen inferior).

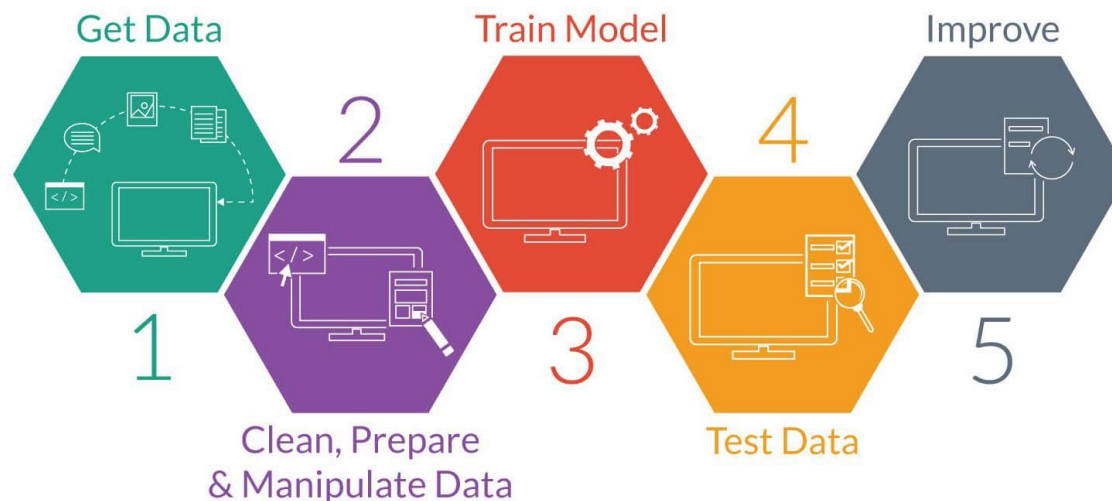
Features					Label
Position	Experience	Skill	Country	City	Salary (\$)
Developer	0	1	USA	New York	103100
Developer	1	1	USA	New York	104900
Developer	2	1	USA	New York	106800
Developer	3	1	USA	New York	108700
Developer	4	1	USA	New York	110400
Developer	5	1	USA	New York	112300
Developer	6	1	USA	New York	114200
Developer	7	1	USA	New York	116100
Developer	8	1	USA	New York	117800
Developer	9	1	USA	New York	119700
Developer	10	1	USA	New York	121600

Terminología básica y notaciones

Existen algoritmos específicos cuyo propósito es “entrenar” los modelos de Machine Learning. Dichos algoritmos proporcionan datos de entrenamiento que permiten a los modelos aprender de ellos.

Con respecto a los algoritmos de Machine Learning, normalmente tienen determinados parámetros “internos”. Por ejemplo en los árboles de decisión, hay parámetros como profundidad máxima del árbol, número de nodos, número de hojas,...a estos parámetros se les llama “hiper parámetros”.

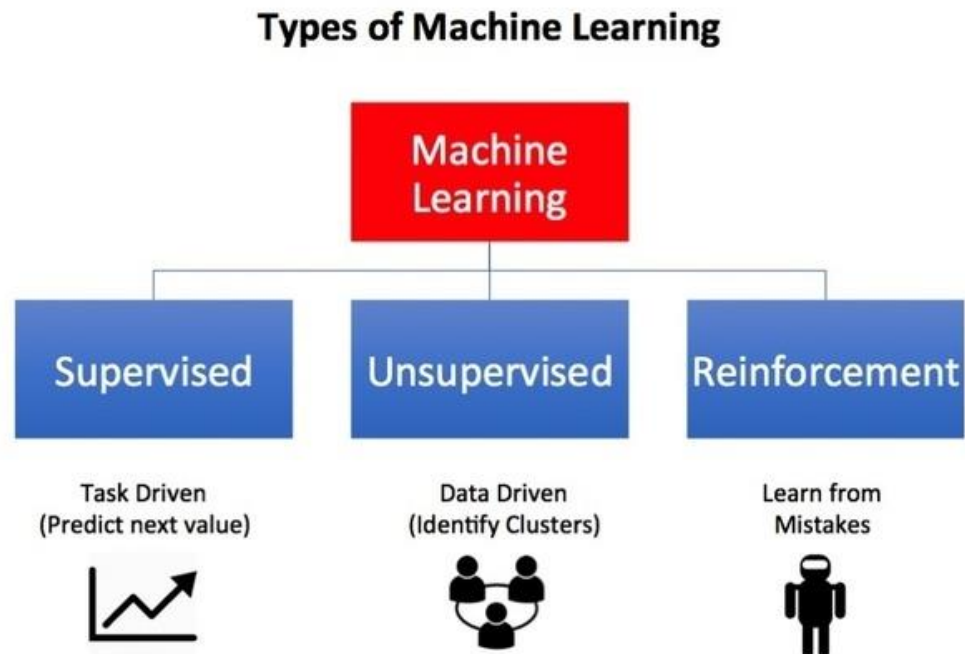
Llamaremos “generalización” a la capacidad del modelo para hacer predicciones utilizando nuevos datos.



Tipos de aprendizaje automático

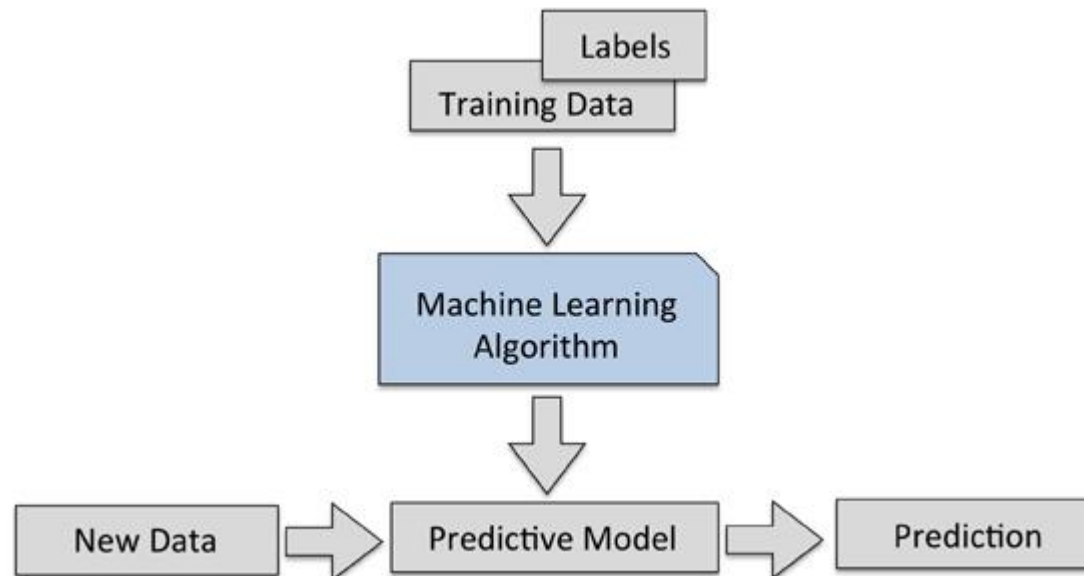
Los tipos de aprendizaje automático pueden clasificarse en tres:

- Aprendizaje supervisado
- Aprendizaje no supervisado
- Aprendizaje profundo



Aprendizaje supervisado


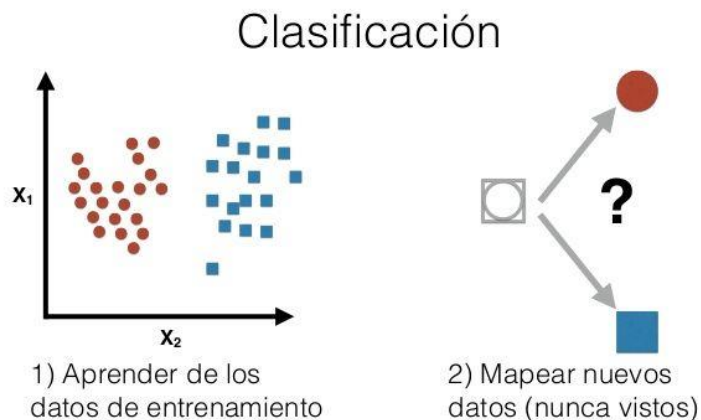
Se refiere a un tipo de modelos de aprendizaje automático que se entrenan con un conjunto de ejemplos en los que los resultados de salida son conocidos. Los modelos aprenden de esos resultados conocidos y realizan ajustes en sus parámetros interiores para adaptarse a los datos de entrada. Una vez el modelo es entrenado adecuadamente, y los parámetros internos son coherentes con los datos de entrada y los resultados de la batería de datos de entrenamiento, el modelo podrá realizar predicciones adecuadas ante nuevos datos no procesados previamente.



Hay dos aplicaciones principales de aprendizaje supervisado: **clasificación y regresión**

1.- Clasificación:


Clasificación es una sub-categoría de aprendizaje supervisado en la que el objetivo es predecir las clases categóricas (valores discretos, no ordenados, pertenencia a grupos). El ejemplo típico es la detección de correo spam, que es una clasificación binaria (un email es spam — valor “1”- o no lo es — valor “0” -). También hay clasificación multi-clase, como el reconocimiento de caracteres escritos a mano (donde las clases van de 0 a 9).



1.- Clasificación:

Un ejemplo de clasificación binaria:

Hay dos clases de objetos, círculos y cruces, y dos características de los objetos, x_1 y x_2 . El modelo puede encontrar las relaciones entre las características de cada punto de datos y su clase, y establecer la línea divisoria entre ellos. Así, al ser alimentado con nuevos datos, el modelo será capaz de determinar la clase a la que pertenecen, de acuerdo con sus características.




En este caso, el nuevo punto de datos entra en el área correspondiente al subespacio de círculos y por tanto, el modelo predecirá que la clase del objeto es círculo.

2.- Regresión:

La regresión se utiliza para asignar categorías a datos sin etiquetar. En este tipo de aprendizaje se tiene un número de variables predictoras (explicativas) y una variable de respuesta continua (resultado), y se tratará de encontrar una relación entre dichas variables que nos proporcione un resultado continuo.

Un ejemplo de regresión lineal:

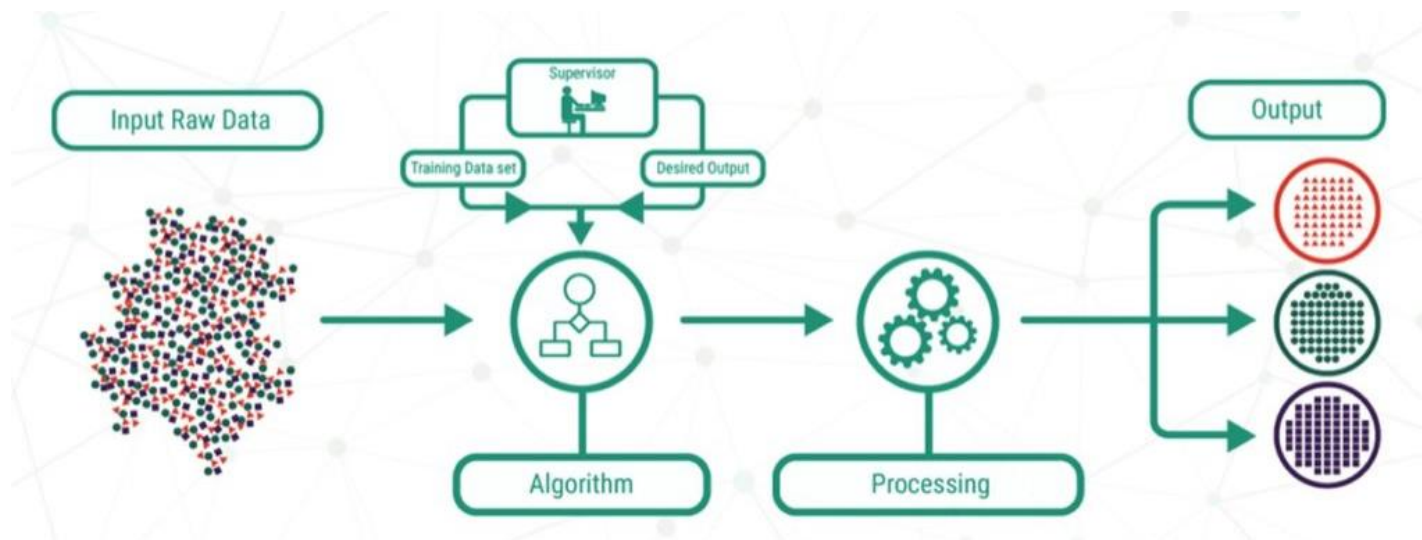
Dados X e Y , establecemos una línea recta que minimice la distancia (con el método de mínimos cuadrados) entre los puntos de muestra y la línea ajustada. Después, se utiliza las desviaciones obtenidas en la formación de la línea para predecir nuevos datos de salida.



Aprendizaje No supervisado

En el aprendizaje no supervisado, trabaja con datos sin etiquetar cuya estructura es desconocida. El objetivo será la extracción de información significativa, sin la referencia de variables de salida conocidas, y mediante la exploración de la estructura de dichos datos sin etiquetar.


Hay dos categorías principales: agrupamiento y reducción dimensional.



1.- Agrupamiento o Clustering:

El agrupamiento es una técnica exploratoria de análisis de datos, que se usa para organizar información en grupos con significado sin tener conocimiento previo de su estructura. Cada grupo es un conjunto de objetos similares que se diferencia de los objetos de otros grupos. El objetivo es obtener un número de grupos de características similares.


Un ejemplo de aplicación de este tipo de algoritmos puede ser para establecer tipos de consumidores en función de sus hábitos de compra, para poder realizar técnicas de marketing efectivas y “personalizadas”.



1.- Reducción dimensional:


Es común trabajar con datos en los que cada observación se presenta con alto número de características, en otras palabras, que tienen alta dimensionalidad. Este hecho es un reto para la capacidad de procesamiento y el rendimiento computacional de los algoritmos de Machine Learning. La reducción dimensional es una de las técnicas usadas para mitigar este efecto.

La reducción dimensional funciona encontrando correlaciones entre las características, lo que implica que existe información redundante, ya que alguna característica puede explicarse parcialmente con otras (por ejemplo, puede existir dependencia lineal). Estas técnicas eliminan “ruido” de los datos (que puede también empeorar el comportamiento del modelo), y comprimen los datos en un sub-espacio más reducido, al tiempo que retienen la mayoría de la información relevante.



Aprendizaje profundo (Deep Learning)

El aprendizaje profundo o Deep Learning, es un subcampo de Machine Learning, que usa una estructura jerárquica de redes neuronales artificiales, que se construyen de una forma similar a la estructura neuronal del cerebro humano, con los nodos de neuronas conectadas como una tela de araña. Esta arquitectura permite abordar el análisis de datos de forma no lineal a través de datos expresados en forma matricial o tensorial.




Aprendizaje profundo (Deep Learning)

La primera capa de la red neuronal toma datos en bruto como entrada, los procesa, extrae información y la transfiere a la siguiente capa como salida. Este proceso se repite en las siguientes capas, cada capa procesa la información proporcionada por la capa anterior, y así sucesivamente hasta que los datos llegan a la capa final, que es donde se obtiene la predicción.

Esta predicción se compara con el resultado conocido, y así por análisis inverso el modelo es capaz de aprender los factores que conducen a salidas adecuadas.

Es uno de los principales algoritmos utilizados en la creación de aplicaciones y programas para reconocimiento de imágenes.



Oportunidades y aplicaciones del Deep learning

Se necesita mucho poder de cómputo para resolver problemas de deep learning debido a la naturaleza iterativa de los algoritmos, su complejidad conforma aumenta el número de capas y los grandes volúmenes de datos que se necesitan para entrenar a las redes.


La naturaleza dinámica de los métodos de deep learning – su capacidad de mejorar y adaptarse continuamente a cambios en el patrón de información implícito – presenta una gran oportunidad para introducir un comportamiento más dinámico a la analítica.

WHY ARE GPUS GOOD FOR DEEP LEARNING?

	Neural Networks	GPUs
Inherently Parallel	✓	✓
Matrix Operations	✓	✓
FLOPS	✓	✓
Bandwidth	✓	✓

GPUs deliver --

- same or **better** prediction accuracy
- faster results
- smaller footprint
- lower power
- lower cost




[Lee, Ranganath & Ng, 2007]

Oportunidades y aplicaciones del Deep learning

El enfoque actual del mercado de las técnicas de Deep Learning está en aplicaciones de cómputo cognitivo, también hay un gran potencial en aplicaciones analíticas más tradicionales; por ejemplo, el análisis de series de tiempo.

Otra oportunidad es simplemente ser más eficiente y simplificado en operaciones analíticas existentes. Recientemente, la empresa SAS experimentó con redes neurales profundas en problemas de transcripción de habla a texto. Comparado con las técnicas estándares, el índice de errores en palabras disminuyó más de 10% cuando se aplicaron redes neurales profundas. También eliminaron cerca de 10 pasos del procesamiento de datos, ingeniería de características y modelado. Los impresionantes incrementos de desempeño y los ahorros de tiempo cuando se comparan con la ingeniería de características se traducen en un cambio de paradigma.



Machine Learning

- ✓ Quick to train a model
- ✓ Accuracy plateaus
- ✓ Good results with small data sets
- ✓ Trains on CPU
- ✓ Try different features to achieve best results


Deep Learning

- ✓ Intensive computation
- ✓ Unlimited accuracy
- ✓ Requires Millions of data points
- ✓ Trains better on GPU
- ✓ Learns features automatically

Tipos de redes neuronales en Deep Learning

El Deep Learning se basa en el uso de las redes neuronales artificiales. Dentro de las redes neuronales hay 3 tipos que son los más usados:

- Convolutional Neural Networks (CNN, redes neuronales convolucionales)
- Recurrent Neural Networks (RNN, redes neuronales recurrentes)
- Generative Adversarial Networks (GAN, redes generativas antagónicas)



Tipos de redes neuronales en Deep Learning

CNN

Las redes neuronales convolucionales son redes neuronales artificiales que han sido diseñadas para procesar matrices estructuradas, como imágenes. Es decir, se encargan de clasificar imágenes basándose en los patrones y objetos que aparecen en ellas, por ejemplo, líneas, círculos o, incluso, ojos y caras.


Por ello, las CNN suelen usarse en computer vision (visión artificial), ya que pueden operar con imágenes brutas (raw images) y no necesitan hacer un procesamiento previo. Esta cualidad hace que sean muy útiles para aplicaciones visuales de clasificación de imágenes, pero también procesamiento del lenguaje natural (natural language processing, nlp), ayudando con la clasificación de textos. Por ejemplo, con el procesamiento del lenguaje natural, se puede identificar si el email que se ha recibido es para finanzas, para comercial o para otro departamento.

1 _{x1}	1 _{x0}	1 _{x1}	0	0
0 _{x0}	1 _{x1}	1 _{x0}	1	0
0 _{x1}	0 _{x0}	1 _{x1}	1	1
0	0	1	1	0
0	1	1	0	0

Image

4		


Convolved
Feature



Tipos de redes neuronales en Deep Learning

CNN

Las redes neuronales convolucionales usan varias capas convolucionales (sobre unas 20-30 capas de media). Las capas convolucionales son un tipo especial de capa que, al apilarse unas encima de otras, permite reconocer formas más sofisticadas. Por ejemplo, con unas 3-4 capas convolucionales se pueden reconocer dígitos escritos a mano y con 25 se reconocen caras humanas. Este tipo de capas imitan a la estructura del cortex visual humano, ya que una serie de capas procesan una imagen entrante e identifican características cada vez más complejas.




Tipos de redes neuronales en Deep Learning

RNN

Las redes neuronales recurrentes son redes neuronales que usan datos secuenciales o datos de series de tiempo. Este tipo de redes solucionan problemas ordinales o temporales, como la traducción de idiomas, reconocimiento de voz (speech recognition), procesamiento de lenguaje natural (NLP, Natural Language Processing) y captura de imágenes. Por eso, estas redes se encuentran en tecnologías como Siri o Google translate. En este caso, el procesamiento natural del lenguaje reconoce el habla de una persona. Por ejemplo, se distingue si la persona que está hablando es hombre o mujer, adulto o menor, si tiene acento, etc. De esta forma, se analiza la forma de hablar de la persona y se consigue llegar a su idiolecto.

Recurrent Neural Networks



Tipos de redes neuronales en Deep Learning

RNN


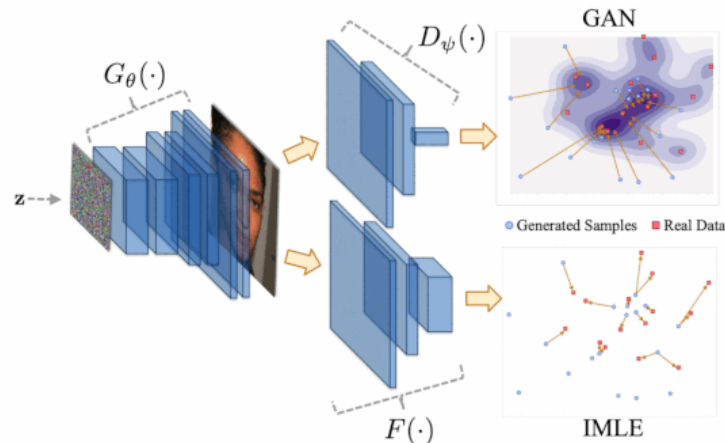
Las redes neuronales recurrentes difieren de otras redes neuronales artificiales en que tienen “memoria”. Es decir, las RNN toman información de inputs anteriores para influenciar los inputs y outputs actuales. Por ejemplo, al escribir con el móvil, el teclado te muestra una serie de palabras como sugerencias a partir de lo que está escrito. Esas sugerencias son las predicciones que se han hecho basándose en los caracteres que fueron escritos con anterioridad.



Tipos de redes neuronales en Deep Learning

GAN

Las redes generativas antagónicas consisten en usar 2 redes neuronales artificiales y oponerlas la una a la otra (por eso se les conoce como antagónicas) para generar nuevo contenido o datos sintéticos que pueden hacerse pasar por reales.



Tipos de redes neuronales en Deep Learning

GAN

Una de las redes genera y la otra funciona como “discriminadora”. La red discriminadora (también conocida como red antagónica) ha sido entrenada para reconocer contenido real y hace de censor para que la red que genera contenido haga contenido que parezca real. Por eso, este tipo de redes son muy usadas para generar imágenes, vídeos y voces. Por ejemplo, NVIDIA desarrolló DCGAN, una tecnología que genera caras de personas que parecen reales, pero no lo son. El problema de este tipo de redes es que también son las que sustentan los deepfakes. No obstante, esta tecnología también ha sido muy útil para recuperar características en imágenes astrofísicas de galaxias muy lejanas o para crear modelos 3D partiendo de imágenes 2D.



Source: <http://gaugan.org/gaugan2/>

Aplicaciones de Deep Learning en el día a día

Detección de fraudes financieros

Las entidades bancarias y otras empresas del sector financiero tienen que hacer grandes esfuerzos en el mundo de la tecnología para poder asegurar su actividad. Una de sus principales tareas en la actualidad es la de detectar los fraudes que surgen durante las transacciones monetarias digitales. Para ello, se centran en el desarrollo de técnicas de prevención basadas en la identificación de patrones de las transacciones de los clientes y sus calificaciones crediticias, buscando si hay comportamientos inusuales. La identificación de los patrones de cada cliente se hace con deep learning y machine learning. De hecho, el banco BBVA trabajó en 2018 con un equipo de investigadores del Massachusetts Institute of Technology (MIT). Juntos desarrollaron un modelo que puede reducir hasta un 54% el nivel de falsos positivos en la detección de operaciones fraudulentas con tarjeta.




Aplicaciones de Deep Learning en el día a día

Mejorar la eficacia de la sanidad

Uno de los sectores donde está teniendo mayor repercusión es en el sector de la salud. Se está usando para la detección de cáncer, de osteoporosis, identificación de trastornos del habla desde la infancia, alzheimer, etc.

La empresa NVIDIA de GPU realizó un estudio en 2018 para el cual entrenaron una red neuronal convolucional con imágenes para clasificar tumores dependiendo del grado, del estado de los receptores de estrógenos, los subtipos intrínsecos de PAM50 (test genético para cáncer de mama) y el subtipo histológico. El algoritmo de deep learning fue capaz de distinguir los tumores de nivel bajo-intermedio y los de gran nivel con un 82% de precisión.



Aplicaciones de Deep Learning en el día a día

La personalización enfocada a la venta o recurrencia

Las tiendas online (e-commerce) cada vez tienen que ser más innovadoras y ofrecer un mejor servicio para competir. Por ello, hay muchas empresas que hacen uso de deep learning para saber qué es lo que le gusta a cada usuario que entra en su web y poder ofrecerle lo que le interesa.

Por ejemplo, cuando una persona entra en Amazon, le muestra productos basados en su historial de búsquedas, relacionado con lo que ha visto últimamente y hasta le propone “darte un capricho” con los objetos que ha puesto en su lista de deseos.

Las plataformas de vídeo y música (como Netflix, HBO, Prime, Disney o Spotify) también lo hacen, proponiéndole al usuario series, películas o músicas basado en su historial.

GLOBAL MACHINE LEARNING MARKET 2020-2024

